

EAJRS Cross Talk Series キックオフイベント報告 （Notta.ai が書き起こした会議録を元に構成されています。）

EAJRS Cross Talk Series

Beyond Transliteration: Romanisation and Word Segmentation in Japanese Metadata

翻字のその先へ：メタデータにおける日本語のローマ字表記と分かち書き

キックオフイベント：2026 年 9 月 25 日開催

登壇者

- 小木曾智信（国立国語研究所）
- 高田智和（国立国語研究所）
- 飯野勝則（国立情報学研究所）
- 神谷信武（チューリッヒ大学図書館・EAJRS 理事）
- Chris Dillon（大英図書館・EAJRS 理事）

司会：大塚靖代（大英図書館）

本ラウンドテーブルについて

本ラウンドテーブルは、EAJRS Cross Talk Series のキックオフイベントとして開催された「なぜ今、日本語のローマ字表記と分かち書きなのか」をテーマとする討論である。

日本語資料の書誌情報やメタデータが国際的に共有・検索・活用される機会が増えるなか、ローマ字表記の役割を改めて考える必要が生じている。特に、AI による翻訳が進展する現在においても、固有名詞や典拠情報など、翻訳だけでは対応しにくい情報を原言語と結び付け、国際的に検索・流通させる仕組みは重要である。

議論では、ローマ字を単なる「日本語をアルファベットに置き換える方法」と捉えるのではなく、誰が、何のために利用するのか、そしてどこで日本語を区切るのかという二つの問題を中心に検討した。

第1部：ローマ字は誰のために、何のために存在するのか

高田氏は、ローマ字表記を考える際には、まず「誰が、何のために使うのか」を明確にする必要があると指摘した。日本語母語話者のための表記、日本語を読めない人への発音提示、図書館メタデータにおける検索・識別・データ連携などでは、それぞれ必要とされる機能が異なる。さらに、ローマ字の利用者には人間だけでなく、検索システム、データベース、AIなども含まれるため、読みやすさ、発音、検索性、機械処理のどれを重視するかによって望ましい方式も変わると整理した。

飯野氏は、国際的な情報流通の観点から、非日本語話者にとって利用しやすい表記の必要性を強調した。ALA-LC 式のような国際的な基準には意義がある一方、それがすべての利用者や言語環境にとって唯一の解決策とは限らないと指摘した。

小木曾氏は、新たな内閣告示によるローマ字規則が主として固有名詞を対象としており、長い日本語テキストの表記や語の区切り方については十分に規定していないことを指摘した。つまり、ローマ字表記を一般的な日本語メタデータに適用するには、翻字方式だけでは解決できない問題が残されている。

神谷氏は、海外の図書館では日本語資料にローマ字メタデータを付与することが不可欠であると説明した。各機関が異なる方式を採用すれば検索性が損なわれるため、一定の共通性が必要となる。一方、実際の運用では、ドイツ語圏の図書館で DIN 規格を用いながら、分かち書きには NII の基準を参照するなど、複数の基準を組み合わせ対応している例も紹介された。

ディロン氏は、日本語学習におけるローマ字の役割にも触れた。漢字習得は日本語学習初期の大きな負担となり得るため、ローマ字を活用して文法や基本文型を先に学ぶことが、学習の継続を支える場合があると説明した。

また、ヘボン式と訓令式の違いも議論された。ヘボン式は英語話者にとって発音を把握しやすい特徴を持つ一方、訓令式は日本語の音韻体系に基づく体系性を重視する。ただし、ヘボン式の「分かりやすさ」は英語話者を前提とした側面があり、フランス語、中国語、韓国語など、英語を母語としない利用者にとって同じように直感的とは限らないことも指摘された。

こうした議論から、ローマ字表記には利用者と目的に応じた多様性があり、単一の「正解」を設定するだけでは十分ではないという認識が共有された。

第2部：ローマ字化と分かち書き

後半では、ローマ字化と分かち書きを切り離して考えることが難しいという点が中心的なテーマとなった。

大塚は、「有楽町」や「新宿区」のような地名をローマ字化する際にも、語を続けて表記するのか、ハイフンを用いるのかなど、さまざまな判断が必要になることを例示した。そして、より本質的な問題は、日本語のどこに語境界を設定するかにあると述べた。

小木曾氏は、日本国憲法前文を例に、漢字かな交じり文では漢字が語の境界を認識する手掛かりとなる一方、仮名やローマ字だけで表記すると語の切れ目が分かりにくくなることを示した。音声ではイントネーションやポーズが補助的な情報となるが、文字表記ではそれらが失われるため、分かち書きが重要になる。

さらに、16世紀の天草版『平家物語』や小学校低学年向け教科書にも分かち書きの実例があることが紹介された。これらの歴史的・教育的事例からも、表音文字だけで日本語を表記する場合には、語境界を示す仕組みが不可欠であることが確認された。

したがって、日本語のローマ字化は、単なる文字変換ではなく、どこで日本語を区切るのかという言語分析を伴う作業であることが改めて示された。

規則運用と AI 活用の課題

分かち書きの規則化には、実務上の難しさもある。

ALA-LC 式には比較的詳細な分かち書き規定があるものの、その規則は約 35 ページに及ぶ。小木曾氏は、コーパスなどで日本語を単語単位に区切るためには、さらに大規模な言語規則が必要になる場合があると説明した。複数の規則が重なる場合の優先順位や例外処理など、規則を細かく定めても曖昧さが残る可能性がある。

飯野氏は、NII の目録情報作成規則にも未定義の部分や規則間の矛盾があり、実際の運用では目録担当者が過去の事例や経験をもとに判断している場合があると述べた。このような個人の技能への依存は、自動化を進めるうえでの課題となる。

一方、生成 AI を用いたローマ字生成では高い精度が得られる例も紹介された。しかし、大文字・小文字、数字表記、固有名詞の扱いなど、細かな判断基準が明文化されていない場合、AI による安定した自動処理は難しい。

高田氏は、ローマ字化を「文字を置き換える作業」と考えるのではなく、日本語の構造を分析して語境界を判断する作業として捉える必要があると整理した。そのうえで、形態素解析や AI などを活用し、実務者の負担を軽減する仕組みの必要性を指摘した。

単一の正解ではなく「渡り」をつくる

議論を通じて、特定のローマ字方式の優劣を決定したり、すべてを一つの規則に統一したりすることが、現時点での主目的ではないという認識が共有された。

むしろ重要なのは、異なるローマ字方式やメタデータを相互に対応付ける「渡り（マッピング）」を整備することである。

図書館員、研究者、教員、学習者など、それぞれが異なる方式を使う現実を前提としながら、どの方式で検索しても必要な資料に到達できるようにする。こうした方式間の連携が整えば、ローマ字表記の多様性を維持しながら、国際的な検索性とデータ連携を高めることができる。

この観点から、ローマ字化は単独の翻字問題ではなく、日本語資料を国際的な情報環境へ接続するためのメタデータ設計の問題として捉える必要がある。

今後の方向性

今回のクロストークでは、図書館、美術館、博物館などで日本語メタデータを扱う実務者が、それぞれの現場で抱える問題を共有しながら、今後のローマ字表記と分かち書きのあり方を継続的に検討していく方向性が確認された。

特に今後は、助詞・助動詞・接辞をどこまで分けるか、大文字化をどのように扱うか、住所や固有名詞におけるハイフンの使用など、具体的な実務上の論点を整理していくことが求められる。

また、規則を際限なく増やすのではなく、AI や形態素解析などの支援技術を活用し、実務者が過度な負担なく一定の共通性を確保できる環境を整えることも重要な課題として示された。

次回のクロストークでは、NII、NDL、OCLC などにおける実際の翻字・分かち書きの事例を参照しながら、より具体的な実務上の課題について議論を深める予定である。

キーポイント

- **ローマ字の目的は一つではない。**
日本語学習、発音提示、図書館での検索・識別、メタデータ連携、AI やデータベースによる処理など、目的によって必要な表記は異なる。
- **ローマ字化の核心は「どこで区切るか」にある。**
漢字が語境界を示す日本語では、ローマ字や仮名だけにすると語の切れ目が分かりにくくなる。そのため、ローマ字化と分かち書きは一体として考える必要がある。
- **方式は国・地域・分野によって異なる。**
ヘボン式、訓令式、ALA-LC、DIN など、それぞれ異なる背景と目的を持つ。単一方式への統一よりも、異なる方式をつなぐ仕組みが重要となる。
- **「渡り（マッピング）」が鍵になる。**
表記方式の違いを乗り越え、どの方式で検索しても同じ資料に到達できるよう、ローマ字表記やメタデータを相互に対応付けることが求められる。
- **AI・形態素解析の活用が期待される。**
ローマ字化は単純な文字変換ではなく、日本語の構造や語境界を判断する作業である。AI などによって実務者の負担を軽減し、表記の一貫性を支える可能性がある。

まとめ

日本語のローマ字化を考えることは、単に日本語をアルファベットに置き換えることではない。誰が何のために使うのか、そして日本語をどこで区切るのかを考える必要がある。

今回の議論では、唯一のローマ字方式を決めることよりも、多様な方式を前提に、それらを相互につなぎ、AI なども活用しながら、日本語資料を国際的に検索・共有できる環境をつくることの重要性が示された。